

---

---

平成28年度数学特別講究第4回  
Simulation and Inference for Stochastic  
Differential Equations

---

---

伊藤克哉

平成28年10月31日

# 目次

<b>第 1 章</b>	<b>Simulation and Inference for Stochastic Differential Equations</b>	<b>2</b>
1.1	Numerical Methods for SDE . . . . .	2
1.1.1	Shoji-Ozaki method . . . . .	2
1.1.2	Exact Sampling . . . . .	2
1.2	Parametric Estimation of SDE . . . . .	3
1.2.1	Exact likelihood inference . . . . .	5
1.2.2	Pseudo-likelihood methods . . . . .	6
1.2.3	Approximated likelihood methods . . . . .	7

# 第1章 Simulation and Inference for Stochastic Differential Equations

## 1.1 Numerical Methods for SDE

### 1.1.1 Shoji-Ozaki method

Shoji-Ozaki 法は,

$$dX_t = b(t, X_t)dt + \sigma dW_t$$

という確率微分方程式の解に対して, これを  $[s, s + \Delta s)$  上で局所的に近似することによって,

$$dX_t = (L_s X_t + t M_s + N_s)dt + \sigma dW_t$$

ただし,

$$L_s = b_x(s, X_s), \quad M_s = \frac{\sigma^2}{2} b_{xx}(s, X_s) + b_t(s, X_s) \\ N_s = b(s, X_s) - X_s b_x(s, X_s) - s M_s$$

に対して,  $Y_t = e^{-L_s t} X_t$  変換することによって,

$$Y_t = Y_s + \int_s^t (M_s u + N_s) e^{-L_s u} du + \sigma \int_s^t e^{-L_s u} dW_u$$

という確率微分方程式が得られるが, これを部分的に解いて,  $X_t$  に戻す事によって,

$$X_{s+\Delta s} = A(X_s)X_s + B(X_s)Z$$

ただし,

$$A(X_s) = 1 + \frac{b(s, X_s)}{X_s L_s} (e^{L_s \Delta s} - 1) + \frac{M_s}{X_s L_s^2} (e^{L_s \Delta s} - 1 - L_s \Delta s) \quad (1.1.1)$$

$$B(X_s) = \sigma \sqrt{\frac{\exp 2L_s \Delta s - 1}{2L_s}}, \quad Z \sim N(0, 1) \quad (1.1.2)$$

### 1.1.2 Exact Sampling

まず, 基本的な場合の棄却法について述べる.

今  $g$  という確率密度関数をもつ確率変数の生成法を知っており,  $f$  という確率密度関数をもつ確率変数を生成したいという状態にあるとする.

ここで,

$$f(x) \leq \epsilon g(x)$$

というような  $\epsilon > 0$  が存在しているとする. このとき次のアルゴリズムに従えば良い.

**方法 1.1.1** 1.  $g$  に従う数  $y$  を 1 つ生成する.

2. 一様分布  $U(0, 1)$  に従う乱数  $u$  を 1 つ生成する.

3.  $u < \epsilon f(y)/g(y)$  を満たすならば,  $y$  を採用し, それ以外ならば 1 に戻る.

これを次のように確率微分方程式に応用する.

今確率微分方程式の係数,  $b$  が  $x$  で偏微分可能であり,  $\frac{1}{2}b^2(x) + \frac{1}{2}b_x(x)$  が上にも下にも有界であると仮定する.

ここで,  $k_1 \leq \frac{1}{2}b^2(x) + \frac{1}{2}b_x(x) \leq k_2$  であるとする.

$$\phi(x) = \frac{1}{2}b^2(x) + \frac{1}{2}b_x(x) - k_1, \quad M = k_2 - k_1$$

とおく.

$$h(z) = \exp\left\{\int_0^z b(u)du - \frac{(z-x)^2}{2\Delta}\right\}$$

を規格化して,  $\hat{h}$  とおく. この時次のアルゴリズムに従えば良い.

- 方法 1.1.2**
1.  $\hat{h}$  に従うような  $y$  を生成する.
  2. 0 のとき 0 で,  $\Delta$  のとき  $y$  のブラウン橋を作る.
  3.  $k$  を  $\lambda = \Delta M$  の *Poisson* 過程から作る.
  4.  $[0, T] \times [0, M]$  上の一様分布の実現  $\{x_1, \dots, x_k\}, x_i = (t_i, v_i)$  を得る.
  5. 全ての  $i$  について  $\phi(y_i) \leq v_i$  ならば採用し, それ以外ならば 1 に戻る.

## 1.2 Parametric Estimation of SDE

$$dX_t = b_\theta(X_t)dt + \sigma_\theta(X_t)dW_t$$

というような  $\theta$  によってパラメトライズされた自励系の確率微分方程式を考える. ここで,  $\theta \in \Theta \subset \mathbb{R}^p$  は  $p$  個のパラメータであり,  $\theta_0$  が推測すべき真のパラメータとする. まずこの過程がエルゴード性を満たし, 連続的である場合には容易に最尤法を適用することができる.

### 定義 1.2.1

$$dX_t = b(X_t)dt + \sigma(X_t)dW_t$$

という自励系の確率微分方程式に対して,

$$\tau_a = \inf\{t \geq 0 | X_t = a\}, \tau_{ab} = \inf\{t \geq \tau_a | X_t = b\}$$

と定める. 過程  $X_t$  が *recurrent* であるとは,  $P(\tau_{ab} < \infty) = 1$  が任意の  $a, b \in \mathbb{R}$  に対して成り立つことである.

*recurrent* な過程  $X_t$  が *positive* であるということは,  $E[\tau_{ab}] < \infty$  が任意の  $a, b \in \mathbb{R}$  に対して成り立つことである.

### 命題 1.2.2

$$dX_t = b(X_t)dt + \sigma(X_t)dW_t$$

という過程が *recurrent* であることは

$$V(x) = \int_0^x \exp\left(-2 \int_0^y \frac{b(u)}{\sigma(u)^2} du\right) dy \rightarrow \pm\infty \quad x \rightarrow \pm\infty$$

ということと同値である.

recurrent な過程が positive であることは

$$G = \int_{-\infty}^{\infty} \sigma(y)^{-2} \exp\left(2 \int_0^y \frac{b(u)}{\sigma(u)^2} du\right) dy < \infty$$

であることと同値である.

Durett p.221 に証明

**定義 1.2.3**  $X_t$  という過程が ergodic であるとは, ある確率変数  $\xi$  が存在して, どのような可測関数  $h(x)$  に対しても

$$\frac{1}{T} \int_0^T h(X_t) dt \rightarrow E[h(\xi)]$$

が成立すること. このとき,  $\xi$  の分布関数を  $\pi$  と置いて, invariant density または stationary density という.

**定理 1.2.4** recurrent で positive な過程は ergodic であり, このとき invariant density  $\pi$  は

$$\pi(x) = \frac{1}{G\sigma(x)^2} \exp\left\{2 \int_0^x \frac{b(y)}{\sigma(y)^2} dy\right\}$$

として表される.

ここで ergodic な過程に対する最尤法を考える.

**定理 1.2.5 (Girsanov)**

$$dX_t = b_1(X_t)dt + \sigma(X_t)dW_t, \quad X_0 = X_0^{(1)} \quad (1.2.1)$$

$$dX_t = b_2(X_t)dt + \sigma(X_t)dW_t, \quad X_0 = X_0^{(2)} \quad (1.2.2)$$

$$dX_t = \sigma(X_t)dW_t, \quad X_0 = X_0 \quad (1.2.3)$$

$$(1.2.4)$$

という  $t \in [0, T]$  上で定義された 3 つのいとう過程を考える. この過程から引き起こされる確率測度を  $P_1, P_2, P_3$  とおく. ここで, 各  $b$  と  $\sigma$  は Global Lipschitz であり, Linear growth であると仮定する (ゆえに各確率微分方程式の解が存在する)

さらに,  $f_1, f_2, f$  という初期値たちの密度関数は同じサポートを持つと仮定する.

このとき次のようにしてこれらの Radon-Nikodym 微分が存在して, 次のように表される.

$$\frac{dP_1}{dP}(X) = \frac{f_1(X_0)}{f(X_0)} \exp\left\{\int_0^T \frac{b_1(X_s)}{\sigma^2(X_s)} dX_s - \frac{1}{2} \int_0^T \frac{b_1^2(X_s)}{\sigma^2(X_s)} ds\right\}$$

$$\frac{dP_2}{dP_1}(X) = \frac{f_2(X_0)}{f_1(X_0)} \exp\left\{\int_0^T \frac{b_2(X_s) - b_1(X_s)}{\sigma^2(X_s)} dX_s - \frac{1}{2} \int_0^T \frac{b_2^2(X_s) - b_1^2(X_s)}{\sigma^2(X_s)} ds\right\}$$

任意の  $\theta$  に対して ergodic な過程に対してはまず, quadratic variation を計算して,

$$\langle X, X \rangle_t = \lim_{n \rightarrow \infty} \sum_{k=1}^{2^n} (X_{t \wedge (k/2^n)} - X_{t \wedge ((k-1)/2^n)})^2 = \int_0^t \sigma^2(X_s, \theta) ds$$

という風にして  $\sigma$  のパラメータを推定することができる。  
その後, Girsanov の定理によって, 次のように尤度が表される。

$$L_T(\theta) = \frac{dP_1}{dP}(X) = \exp\left(\int_0^T \frac{b_\theta(X_s)}{\sigma^2(X_s)} dX_s - \frac{1}{2} \int_0^T \frac{b_\theta^2(X_s)}{\sigma^2(X_s)} ds\right)$$

つまりこの尤度を最大にするような  $\theta$  を求めれば良い。  
しかし実務上このように連続的な尤度を求めることができるのは稀であり次のような幾つかの方法で近似をしなければならない。以下では幾つかの最尤推定法について紹介する。

### 1.2.1 Exact likelihood inference

前述の Ornstein-Uhlenbeck 過程や Geometric Brownian motion や CIR モデルに対しては直接分布を求めて, その尤度を計算することができる。

#### Ornstein-Uhlenbeck model

$$dX_t = (\theta_1 - \theta_2 X_t)dt + \theta_3 dW_t, \quad X_0 = x_0, \quad \theta_1, \theta_2 \in \mathbb{R}, \theta_3 > 0$$

であるような過程に対して, 条件付き密度関数は

$$\begin{aligned} p_\theta(t, \cdot | x) &\sim N(m(t, x), v(t, x)) \\ m(t, x) &= \frac{\theta_1}{\theta_2} + (x_0 - \frac{\theta_1}{\theta_2})e^{-\theta_2 t} \\ v(t, x) &= \frac{\theta_3^2(1 - e^{-2\theta_2 t})}{2\theta_2} \end{aligned}$$

という平均と分散をもつ正規分布に従う。故にこれにより直接尤度を計算することができる。

#### geometric Brownian motion

次のように表される geometric Brownian motion を考える。

$$dX_t = \theta_1 X_t dt + \theta_2 X_t dW_t, \quad X_0 = x_0, \quad \theta_1 \in \mathbb{R}, \quad \theta_2 > 0$$

同様に, このモデルの条件付き密度関数は,

$$\begin{aligned} p_\theta(t, \cdot | x) &\sim LN(m(t, x), v(t, x)) \\ m(t, x) &= x e^{\theta_1 t}, \quad v(t, x) = x^2 e^{2\theta_1 t} (e^{\theta_2^2 t} - 1) \end{aligned}$$

というような対数正規分布によって表される。故にこれにより直接尤度を計算することができる。

#### Cox-Ingersoll-Ross Model

次のように表される Cox-Ingersoll-Ross モデルを考える。

$$dX_t = (\theta_1 - \theta_2 X_t)dt + \theta_3 \sqrt{X_t} dW_t, \quad X_0 = x_0 > 0, \quad \theta_1, \theta_2 \theta_3 > 0$$

同様に, このモデルの条件付き密度関数は,

$$p_\theta(t, \cdot | x) = c \exp -u - v \left( \frac{u}{v} \right)^{q/2} I_q(2\sqrt{uv}), \quad x, y > 0$$

という風に表される。ただし,

$$c = \frac{2\theta_2}{\theta_2^3(1 - e^{-\theta_2 t})}, q = \frac{2\theta_1}{\theta_2^2} - 1$$

$$u = cx \exp -\theta_2 t, v = cy$$

であり,  $I_q$  は修正 Bessel 関数である.

$$I_q(x) = \sum_{k=0}^{\infty} \left(\frac{x}{2}\right)^{2k+q} \frac{1}{k! \Gamma(k+q+1)}$$

### 1.2.2 Pseudo-likelihood methods

SDE の離散近似スキームを使ってパスを生成し, 過程の尤度を求める方法を Pseudo-likelihood 法という.

#### Euler method

$$dX_t = b_\theta(X_t)dt + \sigma_\theta(X_t)dW_t$$

という確率微分方程式に対して Euler-Maruyama 近似を適用すると,

$$\Delta X = b_\theta(X_t)\Delta t + \sigma_\theta(X_t)\Delta W_t$$

であるので,  $\Delta X$  はそれぞれ, 平均  $b_\theta(X_t)$  分散  $\sigma_\theta^2(X_t)$  の正規分布に従っている. 故に, Euler-Maruyama 近似が強収束するとき, この対数尤度  $l_n(\theta)$  は

$$l_n(\theta) = -\frac{1}{2} \left\{ \sum_{i=1}^n \frac{(X_i - X_{i-1} - b(X_{i-1}, \theta)\Delta)^2}{\sigma^2 \Delta} + n \log(2\pi \sigma^2 \Delta) \right\}$$

という式によって表される. また N.Yoshida(1992) によると,

$$\hat{\sigma}^2 = \frac{1}{n\Delta} \sum_{i=1}^n (X_i - X_{i-1})^2$$

によって  $\sigma$  を推定することができる. ここで, 最初に述べた Exact likelihood と Euler approximation の性質を見してみる.

$$dX_t = (\theta_1 - \theta_2 X_t)dt + \theta_3 dW_t, X_0 = x_0, \theta_1, \theta_2 \in \mathbb{R}, \theta_3 > 0$$

という Ornstein-Uhlenbeck 過程に対して 2 つの方法を適用しすると,

$$m(\Delta, x) = x \exp(-\theta_2 \Delta) + \frac{\theta_1}{\theta_2} (1 - \exp(-\theta_2 \Delta)), v(\Delta, x) = \frac{\theta_3^2 (1 - \exp(-2\theta_2 \Delta))}{2\theta_2}$$

という平均と分散が得られ, また Euler approximation を行うと,

$$m(\Delta, x) = x(1 - \theta_2 \Delta) + \theta_1 \Delta, v(\Delta, x) = \theta_3^2 \Delta$$

という平均と分散が得られる. これらは,  $\Delta \rightarrow 0$  では一致する. 一方で,

$$dX_t = \theta_1 X_t dt + \theta_2 X_t dW_t, X_0 = x_0, \theta_1 \in \mathbb{R}, \theta_2 > 0$$

という geometric Brownian motion を考える. この時, 上の式出てきた最尤法を当てはめると,

$$\hat{\theta}_{1,n} = \frac{1}{n\Delta} \sum_{i=1}^n \left( \frac{X_i}{X_{i-1}} - 1 \right), \hat{\theta}_{2,n} = \frac{1}{n\Delta} \sum_{i=1}^n \left( \frac{X_i}{X_{i-1}} - 1 - \hat{\theta}_{1,n}^2 \Delta \right),$$

という最尤推定値を得る. ここで,  $\Delta$  が無視できないほど大きい場合を考えると,

$$\hat{\theta}_{1,n} \rightarrow \frac{1}{\Delta} (e^{\theta_1 \Delta} - 1) \neq \theta_1, \hat{\theta}_{2,n} \rightarrow \frac{1}{\Delta} e^{2\theta_1 \Delta} (e^{\theta_2^2 \Delta} - 1) \neq \theta_2$$

という確率収束が得られるので,  $\Delta$  の影響は大きい.

## Elerian method

Milstein 近似により,

$$\Delta X_t = b(t, X_t)\Delta t + \sigma(t, X_t)\Delta W + \frac{1}{2}\sigma(t, X_t)\sigma_x(t, X_t)((\Delta W)^2 - \Delta t)$$

という近似式が得られている. このとき次の定理が成り立つ

**定理 1.2.6** *Milstein* 近似がオーダー 1 で強収束しているとき

$$p(t, y|x) = \frac{z^{-1/2} \cosh(\sqrt{C}z)}{|A|\sqrt{2\pi}} \exp\left(-\frac{C+z}{2}\right)$$

として得られる. ただし,

$$A = \frac{\sigma(x)\sigma_x(x)t}{2}, B = -\frac{\sigma(x)}{2\sigma_x(x)} + x + b(x)t - A,$$

$$z = \frac{y-B}{A}, C = \frac{1}{\sigma_x^2(x)t}$$

## Shoji-Ozaki method

Shoji-Ozaki 法は,

$$dX_t = b(t, X_t)dt + \sigma dW_t$$

という確率微分方程式の解に対して, これを  $[s, s + \Delta s)$  上で局所的に近似することによって,

$$dX_t = (L_s X_t + t M_s + N_s)dt + \sigma dW_t$$

ただし,

$$L_s = b_x(s, X_s), M_s = \frac{\sigma^2}{2}b_{xx}(s, X_s) + b_t(s, X_s)$$

$$N_s = b(s, X_s) - X_s b_x(s, X_s) - s M_s$$

に対して,  $Y_t = e^{-L_s t} X_t$  変換することによって,

$$Y_t = Y_s + \int_s^t (M_s u + N_s) e^{-L_s u} du + \sigma \int_s^t e^{-L_s u} dW_u$$

という確率微分方程式が得られるが, これを部分的に解いて,  $X_t$  に戻す事によって,

$$X_{s+\Delta s} = A(X_s)X_s + B(X_s)Z$$

ただし,

$$A(X_s) = 1 + \frac{b(s, X_s)}{X_s L_s} (e^{L_s \Delta s} - 1) + \frac{M_s}{X_s L_s^2} (e^{L_s \Delta s} - 1 - L_s \Delta s) \quad (1.2.5)$$

$$B(X_s) = \sigma \sqrt{\frac{\exp 2L_s \Delta s - 1}{2L_s}}, Z \sim N(0, 1) \quad (1.2.6)$$

である. これを利用することによって, 尤度関数を計算することができる.

### 1.2.3 Approximated likelihood methods

次に, パスを近似するのではなく直接尤度を近似する方法について考える.



## Kessler method

ここで,

$$dX_t = b_\theta(X_t)dt + \sigma_\theta(X_t)dW_t$$

というような自励系の ergodic な確率過程を考える.

ここで

$$t_i^n = i\Delta_n$$

とおいて, この幅で離散化することを考える.

ここで, Ito-Taylor 展開を考え,

$$r_l(\Delta_n, x, \alpha) = \sum_{i=0}^l \frac{\Delta_n^i}{i!} L_\alpha^i f(x)$$

という第  $l$  項まで展開したものを考える. このとき,  $n\Delta_n^p \rightarrow 0$  であるとして,  $k_0 = [p/2]$  と定めると次のようにして, 尤度を定めることができる.

$$l_{p,n}(\alpha) = \sum_{i=1}^n \frac{(X_{t_i^n} - r_{k_0}(\Delta_n, X_{t_{i-1}^n}, \alpha))^2}{\Delta_n \sigma_{i-1}^2(\theta)} \left\{ 1 + \sum_{j=1}^{k_0} \Delta_n^j d_j(X_{t_{i-1}^n}, \alpha) \right\} + \sum_{i=1}^n \left\{ \log c_{i-1}(\theta) + \sum_{j=1}^{k_0} \Delta_n^j e_j(X_{t_{i-1}^n}, \alpha) \right\}$$

ただし,  $d_j, e_j$  は特別な関数の Taylor 展開をしたときの係数である.

## Simulated likelihood method

$p_\theta(\Delta, y|x)$  を求めることを考える.  $\delta \ll \Delta$  とする. このとき,

$$p_\theta(\Delta, y|x) = \int p_\theta(\delta, y|z) p_\theta(\Delta - \delta, z|x) dz = E_z[p_\theta(\delta, y|z)|\Delta - \delta]$$

であることがわかる. ここで, 右の期待値を Monte Carlo 法によって求めると,  $p_\theta(\Delta - \delta, z|x)$  は正規分布であるので,

$$\hat{p}_\theta^{(N,M)}(\Delta, X_{t+\Delta}|x) = \frac{1}{M} \sum_{i=1}^M \phi_\theta(\delta, X_{t+\Delta}|z_i)$$

として, 確率密度関数を求めることができる.

## Hermite polynomials expansion of the likelihood

$$H_j(z) = e^{\frac{z^2}{2}} \frac{d^j}{dz^j} e^{-\frac{z^2}{2}}$$

という修正 Hermite 多項式を考える. ここで, 今までと同様に  $X_t$  という伊藤過程に対して,

$$F(\gamma) = \int_0^\gamma \frac{du}{\sigma_\theta(u)}$$

という Lamperti 変換を加えることによって, まず

$$dY_t = \mu_Y(Y_t, \theta)dt + dW_t$$

という風に変換する. その次に,

$$Z = \Delta^{-1/2}(Y - y_0)$$

という変換を施して,

$$p_Z(\Delta, z|y_0, \theta) = \Delta^{1/2} p_Y(\Delta, \Delta^{1/2}z + y_0|y_0, \theta)$$

という確率密度関数を求めることを考える. ここで,  $H_j(z)/\sqrt{j!}$  は  $L^2$  空間の直交基底であることを使うと,  $p_Z$  を分解することができる. そして, その展開を途中で打ち切ることによって, 尤度の近似を行う.