

# Parametric Estimation of SDE

伊藤克哉

東京大学

2016/10/31

講義ノート   スライド   コードは  
<https://github.com/KatsuyaITO/NSofSDE>

## 1 Numerical methods for SDE

- Lamperti transform
- Shoji-Ozaki method
- Exact Sampling

## 2 Parametric Estimation of SDE

- Exact likelihood inference
  - Ornstein-Uhlenbeck model
  - Cox-Ingersoll-Ross Model
- Pseudo-likelihood methods
  - Euler method
  - Elerian method
  - Shoji-Ozaki method
- Approximated likelihood methods
  - Kessler method
  - Hermite polynomials expansion of the likelihood

# Lamperti transform

以下では

$$dX_t = b(t, X_t)dt + \sigma(X_t)dW_t$$

という SDE の解  $X_t$  について考える. このとき,

$$Y_t = F(X_t) = \int_z^{X_t} \frac{1}{\sigma(u)} du$$

という変換を施すと,

$$dY_t = b_Y(t, Y_t)dt + dW_t$$

とできる.

# Shoji-Ozaki method

Shoji-Ozaki 法

$$dX_t = b(t, X_t)dt + \sigma dW_t$$

という SDE を  $[s, s + \Delta s)$  上で局所的に近似

$$dX_t = (L_s X_t + tM_s + N_s)dt + \sigma dW_t$$

ただし,

$$L_s = b_x(s, X_s), \quad M_s = \frac{\sigma^2}{2} b_{xx}(s, X_s) + b_t(s, X_s)$$

$$N_s = b(s, X_s) - X_s b_x(s, X_s) - s M_s$$

# Shoji-Ozaki method

$X_t$  に対して,  $Y_t = e^{-L_s t} X_t$  変換することによって,

$$Y_t = Y_s + \int_s^t (M_s u + N_s) e^{-L_s u} du + \sigma \int_s^t e^{-L_s u} dW_u$$

という SDE が得られる.

# Shoji-Ozaki method

$X_t$  に対して,  $Y_t = e^{-L_s t} X_t$  変換することによって,

$$Y_t = Y_s + \int_s^t (M_s u + N_s) e^{-L_s u} du + \sigma \int_s^t e^{-L_s u} dW_u$$

という SDE が得られる.

これを部分的に解いて,  $X_t$  に戻す事によって,

$$X_{s+\Delta s} = A(X_s)X_s + B(X_s)Z$$

ただし,

$$A(X_s) = 1 + \frac{b(s, X_s)}{X_s L_s} (e^{L_s \Delta s} - 1) + \frac{M_s}{X_s L_s^2} (e^{L_s \Delta s} - 1 - L_s \Delta s) \quad (1.1)$$

$$B(X_s) = \sigma \sqrt{\frac{\exp 2L_s \Delta s - 1}{2L_s}}, \quad Z \sim N(0, 1) \quad (1.2)$$

# Exact Sampling(基本的な場合の棄却法)

$g$  という確率密度関数をもつ確率変数の生成法を知っている.  
 $f$  という確率密度関数をもつ確率変数を生成したい

$$f(x) \leq \epsilon g(x)$$

というような  $\epsilon > 0$  が存在しているとする.  
このとき次のアルゴリズムに従えば良い.

- ①  $g$  に従う数  $y$  を 1 つ生成する.
- ② 一様分布  $U(0, 1)$  に従う乱数  $u$  を 1 つ生成する.
- ③  $u < \epsilon f(y)/g(y)$  を満たすならば,  $y$  を採用し, それ以外ならば 1 に戻る.



# Exact Sampling(確率微分方程式に応用)

$b$  が  $x$  で偏微分可能であり,  $\frac{1}{2}b^2(x) + \frac{1}{2}b_x(x)$  が上にも下にも有界であると仮定する.

ここで,  $k_1 \leq \frac{1}{2}b^2(x) + \frac{1}{2}b_x(x) \leq k_2$  であるとする.

$$\phi(x) = \frac{1}{2}b^2(x) + \frac{1}{2}b_x(x) - k_1, \quad M = k_2 - k_1$$

とおく.

$$h(z) = \exp \left\{ \int_0^z b(u) du - \frac{(z-x)^2}{2\Delta} \right\}$$

を規格化して,  $\hat{h}$  とおく. この時次のアルゴリズムに従えば良い.

# Exact Sampling

- 1  $\hat{h}$  に従うような  $y$  を生成する.
- 2 0 のとき 0 で,  $\Delta$  のとき  $y$  のブラウン橋を作る.
- 3  $k$  を  $\lambda = \Delta M$  の Poisson 過程から作る.
- 4  $[0, T] \times [0, M]$  上の一様分布の実現  $\{x_1, \dots, x_k\}, x_i = (t_i, v_i)$  を得る.
- 5 全ての  $i$  について  $\phi(y_i) \leq v_i$  ならば採用し, それ以外ならば 1 に戻る.

# Continuous な場合

$$dX_t = b_\theta(X_t)dt + \sigma_\theta(X_t)dW_t$$

$\theta$  によりパラメトライズされた自励系の SDE.

$\theta \in \Theta \subset \mathbb{R}^p$  は  $p$  個のパラメータであり,  $\theta_0$  を推測する.

# ergodic な場合

過程がエルゴード性を満たし、連続的である場合には容易に最尤法を適用することができる。

連続的な場合は実務上は起こりにくいが、理論的には重要である

# ergodic とは

## 定義 2.1

$X_t$  という過程が *ergodic* であるとは,  $\exists \xi$ : 確率変数,  $\forall h(x)$ : 可測関数

$$\lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T h(X_t) dt \rightarrow E[h(\xi)]$$

が成立すること.

このとき,  $\xi$  の分布関数を  $\pi$  と置いて, **invariant density** または *stationary density* という.

# ergodic の特徴付け

## 定理 2.2

*recurrent* で *positive* な過程は *ergodic* であり, このとき *invariant density*  $\pi$  は

$$\pi(x) = \frac{1}{G\sigma(x)^2} \exp\left\{2 \int_0^x \frac{b(y)}{\sigma(y)^2} dy\right\}$$

として表される.

# recurrent と positive とは

## 定義 2.3

$$\tau_a = \inf\{t \geq 0 | X_t = a\}, \tau_{ab} = \inf\{t \geq \tau_a | X_t = b\}$$

と定める. 過程  $X_t$  が **recurrent** であるとは,  $P(\tau_{ab} < \infty) = 1$  が任意の  $a, b \in \mathbb{R}$  に対して成り立つことである.

**recurrent** な過程  $X_t$  が **positive** であるということは,  $E[\tau_{ab}] < \infty$  が任意の  $a, b \in \mathbb{R}$  に対して成り立つことである.

# recurrent と positive に対する特徴付け

## 命題 2.4

$$dX_t = b(X_t)dt + \sigma(X_t)dW_t$$

という過程が *recurrent* である  $\Leftrightarrow$

$$V(x) = \int_0^x \exp\left(-2 \int_0^y \frac{b(u)}{\sigma(u)^2} du\right) dy \rightarrow \pm\infty \quad x \rightarrow \pm\infty$$

*recurrent* な過程が *positive* である  $\Leftrightarrow$

$$G = \int_{-\infty}^{\infty} \sigma(y)^{-2} \exp\left(2 \int_0^y \frac{b(u)}{\sigma(u)^2} du\right) dy < \infty$$



# ergodic な場合の最尤推定

任意の  $\theta$  に対して ergodic な過程を考える.

# ergodic な場合の最尤推定

任意の  $\theta$  に対して ergodic な過程を考える. まず quadratic variation を計算して,

$$\langle X, X \rangle_t = \lim_{n \rightarrow \infty} \sum_{k=1}^{2^n} (X_{t \wedge (k/2^n)} - X_{t \wedge ((k-1)/2^n)})^2 = \int_0^t \sigma^2(X_s, \theta) ds$$

$\sigma$  のパラメータを推定する.

# ergodic な場合の最尤推定

任意の  $\theta$  に対して ergodic な過程を考える. まず quadratic variation を計算して,

$$\langle X, X \rangle_t = \lim_{n \rightarrow \infty} \sum_{k=1}^{2^n} (X_{t \wedge (k/2^n)} - X_{t \wedge ((k-1)/2^n)})^2 = \int_0^t \sigma^2(X_s, \theta) ds$$

$\sigma$  のパラメータを推定する.

その後, Girsanov の定理によって, 次のように尤度が表される.

$$L_T(\theta) = \frac{dP_1}{dP}(X) = \exp\left(\int_0^T \frac{b_\theta(X_s)}{\sigma^2(X_s)} dX_s - \frac{1}{2} \int_0^T \frac{b_\theta^2(X_s)}{\sigma^2(X_s)} ds\right)$$

つまりこの尤度を最大にするような  $\theta$  を求めれば良い.

# Girsanov の定理

## 定理 2.5 (Girsanov)

$$dX_t = b_1(X_t)dt + \sigma(X_t)dW_t, \quad X_0 = X_0^{(1)} \quad (2.1)$$

$$dX_t = b_2(X_t)dt + \sigma(X_t)dW_t, \quad X_0 = X_0^{(2)} \quad (2.2)$$

$$dX_t = \sigma(X_t)dW_t, \quad X_0 = X_0 \quad (2.3)$$

という  $t \in [0, T]$  上で定義された 3つの伊藤過程を考える.

この過程から引き起こされる確率測度を  $P_1, P_2, P_3$  とおく.

ここで, 各  $b$  と  $\sigma$  は *Global Lipschitz* であり, *Linear growth* であると仮定する (ゆえに各確率微分方程式の解が存在する)

さらに,  $f_1, f_2, f$  という初期値たちの密度関数は同じサポートを持つと仮定する.

# Girsanov の定理

このとき次のようにしてこれらの Radon-Nikodym 微分が存在して, 次のように表される.

$$\frac{dP_1}{dP}(X) = \frac{f_1(X_0)}{f(X_0)} \exp \left\{ \int_0^T \frac{b_1(X_s)}{\sigma^2(X_s)} dX_s - \frac{1}{2} \int_0^T \frac{b_1^2(X_s)}{\sigma^2(X_s)} ds \right\}$$

$$\frac{dP_2}{dP_1}(X) = \frac{f_2(X_0)}{f_1(X_0)} \exp \left\{ \int_0^T \frac{b_2(X_s) - b_1(X_s)}{\sigma^2(X_s)} dX_s - \frac{1}{2} \int_0^T \frac{b_2^2(X_s) - b_1^2(X_s)}{\sigma^2(X_s)} ds \right\}$$

# Exact likelihood inference

$$dX_t = (\theta_1 - \theta_2 X_t)dt + \theta_3 dW_t, \quad X_0 = x_0, \quad \theta_1, \theta_2 \in \mathbb{R}, \theta_3 > 0$$

であるような Ornstein-Uhlenbeck 過程に対して, 条件付き密度関数は

$$p_\theta(t, \cdot | x) \sim N(m(t, x), v(t, x))$$

$$m(t, x) = \frac{\theta_1}{\theta_2} + (x_0 - \frac{\theta_1}{\theta_2})e^{-\theta_2 t}$$

$$v(t, x) = \frac{\theta_3^2(1 - e^{-2\theta_2 t})}{2\theta_2}$$

という平均と分散をもつ正規分布に従う. 故にこれにより直接尤度を計算することができる.

# geometric Brownian motion

次のように表される geometric Brownian motion を考える.

$$dX_t = \theta_1 X_t dt + \theta_2 X_t dW_t, \quad X_0 = x_0, \quad \theta_1 \in \mathbb{R}, \quad \theta_2 > 0$$

同様に, このモデルの条件付き密度関数は,

$$p_\theta(t, \cdot | x) \sim LN(m(t, x), v(t, x))$$

$$m(t, x) = xe^{\theta_1 t}, \quad v(t, x) = x^2 e^{2\theta_1 t} (e^{\theta_2^2 t} - 1)$$

というような対数正規分布によって表される. 故にこれにより直接尤度を計算することができる.

# Cox-Ingersoll-Ross Model

次のように表される Cox-Ingersoll-Ross モデルを考える.

$$dX_t = (\theta_1 - \theta_2 X_t)dt + \theta_3 \sqrt{X_t} dW_t, \quad X_0 = x_0 > 0, \quad \theta_1, \theta_2, \theta_3 > 0$$

同様に, このモデルの条件付き密度関数は,

$$p_\theta(t, \cdot | x) = c \exp -u - v \left( \frac{u}{v} \right)^{q/2} I_q(2\sqrt{uv}), \quad x, y > 0$$

という風に表される. ただし,

$$c = \frac{2\theta_2}{\theta_3^3(1 - e^{-\theta_2 t})}, \quad q = \frac{2\theta_1}{\theta_3^2} - 1$$

$$u = cx \exp -\theta_2 t, \quad v = cy$$

であり,  $I_q$  は修正 Bessel 関数である.

$$I_q(x) = \sum_{k=0}^{\infty} \left( \frac{x}{2} \right)^{2k+q} \frac{1}{k! \Gamma(k+q+1)}$$



# Pseudo-likelihood methods

SDE の離散近似スキームを使ってパスを生成し, 過程の尤度を求める方法を **Pseudo-likelihood 法** という.

ここでは,

- 1 Euler method
- 2 Elerian method
- 3 Shoji-Ozaki method

について考える.

# Euler method

$$dX_t = b_\theta(X_t)dt + \sigma_\theta(X_t)dW_t$$

という確率微分方程式に対して Euler-Maruyama 近似を適用すると,

$$\Delta X = b_\theta(X_t)\Delta t + \sigma_\theta(X_t)\Delta W_t$$

であるので, $\Delta X$  はそれぞれ, 平均  $b_\theta(X_t)$  分散  $\sigma_\theta^2(X_t)$  の正規分布に従っている.

# Euler method

故に,Euler-Maruyama 近似が強収束するとき,この対数尤度  $l_n(\theta)$  は

$$l_n(\theta) = -\frac{1}{2} \left\{ \sum_{i=1}^n \frac{(X_i - X_{i-1} - b(X_{i-1}, \theta)\Delta)^2}{\sigma^2 \Delta} + n \log(2\pi\sigma^2\Delta) \right\}$$

という式によって表される.

N.Yoshida(1992) によると,

$$\hat{\sigma}^2 = \frac{1}{n\Delta} \sum_{i=1}^n (X_i - X_{i-1})^2$$

によって  $\sigma$  を推定することができる.

# Exact Likelihood v.s. Euler

ここで、最初に述べた Exact likelihood と Euler approximation の性質を見てみる.

$$dX_t = (\theta_1 - \theta_2 X_t)dt + \theta_3 dW_t, \quad X_0 = x_0, \quad \theta_1, \theta_2 \in \mathbb{R}, \theta_3 > 0$$

という Ornstein-Uhlenbeck 過程に対して 2 つの方法を適用しすると,

# Exact Likelihood v.s. Euler

ここで, 最初に述べた Exact likelihood と Euler approximation の性質を見てみる.

$$dX_t = (\theta_1 - \theta_2 X_t)dt + \theta_3 dW_t, \quad X_0 = x_0, \quad \theta_1, \theta_2 \in \mathbb{R}, \theta_3 > 0$$

という Ornstein-Uhlenbeck 過程に対して 2 つの方法を適用しすると,

$$m(\Delta, x) = x \exp(-\theta_2 \Delta) + \frac{\theta_1}{\theta_2} (1 - \exp(-\theta_2 \Delta)), \quad v(\Delta, x) = \frac{\theta_3^2 (1 - \exp(-2\theta_2 \Delta))}{2\theta_2}$$

という平均と分散が得られ, また Euler approximation を行くと,

# Exact Likelihood v.s. Euler

ここで, 最初に述べた Exact likelihood と Euler approximation の性質を見てみる.

$$dX_t = (\theta_1 - \theta_2 X_t)dt + \theta_3 dW_t, \quad X_0 = x_0, \quad \theta_1, \theta_2 \in \mathbb{R}, \theta_3 > 0$$

という Ornstein-Uhlenbeck 過程に対して 2 つの方法を適用しすると,

$$m(\Delta, x) = x \exp(-\theta_2 \Delta) + \frac{\theta_1}{\theta_2} (1 - \exp(-\theta_2 \Delta)), \quad v(\Delta, x) = \frac{\theta_3^2 (1 - \exp(-2\theta_2 \Delta))}{2\theta_2}$$

という平均と分散が得られ, また Euler approximation を行うと,

$$m(\Delta, x) = x(1 - \theta_2 \Delta) + \theta_1 \Delta, \quad v(\Delta, x) = \theta_3^2 \Delta$$

という平均と分散が得られる. これらは,  $\Delta \rightarrow 0$  では一致する.

# Exact Likelihood v.s. Euler

一方で,

$$dX_t = \theta_1 X_t dt + \theta_2 X_t dW_t, \quad X_0 = x_0, \quad \theta_1 \in \mathbb{R}, \quad \theta_2 > 0$$

という geometric Brownian motion を考える. この時, 上の式出てきた最尤法を当てはめると,

# Exact Likelihood v.s. Euler

一方で,

$$dX_t = \theta_1 X_t dt + \theta_2 X_t dW_t, \quad X_0 = x_0, \quad \theta_1 \in \mathbb{R}, \quad \theta_2 > 0$$

という geometric Brownian motion を考える. この時, 上の式出てきた最尤法を当てはめると,

$$\hat{\theta}_{1,n} = \frac{1}{n\Delta} \sum_{i=1}^n \left( \frac{X_i}{X_{i-1}} - 1 \right), \quad \hat{\theta}_{2,n} = \frac{1}{n\Delta} \sum_{i=1}^n \left( \frac{X_i}{X_{i-1}} - 1 - \hat{\theta}_{1,n}^2 \Delta \right),$$

という最尤推定値を得る. ここで,  $\Delta$  が無視できないほど大きい場合を考えると,



# Exact Likelihood v.s. Euler

一方で,

$$dX_t = \theta_1 X_t dt + \theta_2 X_t dW_t, \quad X_0 = x_0, \quad \theta_1 \in \mathbb{R}, \quad \theta_2 > 0$$

という geometric Brownian motion を考える. この時, 上の式出てきた最尤法を当てはめると,

$$\hat{\theta}_{1,n} = \frac{1}{n\Delta} \sum_{i=1}^n \left( \frac{X_i}{X_{i-1}} - 1 \right), \quad \hat{\theta}_{2,n} = \frac{1}{n\Delta} \sum_{i=1}^n \left( \frac{X_i}{X_{i-1}} - 1 - \hat{\theta}_{1,n}^2 \Delta \right),$$

という最尤推定値を得る. ここで,  $\Delta$  が無視できないほど大きい場合を考えると,

$$\hat{\theta}_{1,n} \rightarrow \frac{1}{\Delta} (e^{\theta_1 \Delta} - 1) \neq \theta_1, \quad \hat{\theta}_{2,n} \rightarrow \frac{1}{\Delta} e^{2\theta_1 \Delta} (e^{\theta_2^2 \Delta} - 1) \neq \theta_2$$

という確率収束が得られるので,  $\Delta$  の影響は大きい.

# Eulerian method

Milstein 近似により,

$$\Delta X_t = b(t, X_t)\Delta t + \sigma(t, X_t)\Delta W + \frac{1}{2}\sigma(t, X_t)\sigma_x(t, X_t)((\Delta W)^2 - \Delta t)$$

## 定理 2.6

*Milstein* 近似がオーダー 1 で強収束しているとき

$$p(t, y|x) = \frac{z^{-1/2} \cosh(\sqrt{Cz})}{|A|\sqrt{2\pi}} \exp\left(-\frac{C+z}{2}\right)$$

として得られる. ただし,

$$A = \frac{\sigma(x)\sigma_x(x)t}{2}, B = -\frac{\sigma(x)}{2\sigma_x(x)} + x + b(x)t - A,$$

$$z = \frac{y - B}{A}, C = \frac{1}{\sigma_x^2(x)t}$$

# Shoji-Ozaki method

Shoji-Ozaki 法

$$dX_t = b(t, X_t)dt + \sigma dW_t$$

という SDE を  $[s, s + \Delta s)$  上で局所的に近似

$$dX_t = (L_s X_t + tM_s + N_s)dt + \sigma dW_t$$

ただし,

$$L_s = b_x(s, X_s), \quad M_s = \frac{\sigma^2}{2} b_{xx}(s, X_s) + b_t(s, X_s)$$

$$N_s = b(s, X_s) - X_s b_x(s, X_s) - s M_s$$

# Shoji-Ozaki method

$X_t$  に対して,  $Y_t = e^{-L_s t} X_t$  変換することによって,

$$Y_t = Y_s + \int_s^t (M_s u + N_s) e^{-L_s u} du + \sigma \int_s^t e^{-L_s u} dW_u$$

という SDE が得られる.

# Shoji-Ozaki method

$X_t$  に対して,  $Y_t = e^{-L_s t} X_t$  変換することによって,

$$Y_t = Y_s + \int_s^t (M_s u + N_s) e^{-L_s u} du + \sigma \int_s^t e^{-L_s u} dW_u$$

という SDE が得られる.

これを部分的に解いて,  $X_t$  に戻す事によって,

$$X_{s+\Delta s} = A(X_s)X_s + B(X_s)Z$$

ただし,

$$A(X_s) = 1 + \frac{b(s, X_s)}{X_s L_s} (e^{L_s \Delta s} - 1) + \frac{M_s}{X_s L_s^2} (e^{L_s \Delta s} - 1 - L_s \Delta s) \quad (2.4)$$

$$B(X_s) = \sigma \sqrt{\frac{\exp 2L_s \Delta s - 1}{2L_s}}, \quad Z \sim N(0, 1) \quad (2.5)$$

である. これを利用することによって, 尤度関数を計算することができる.

# Approximated likelihood methods

次に, パスを近似するのではなく直接尤度を近似する **Approximated likelihood methods** について考える.

- ① Kessler method
- ② Simulated likelihood method
- ③ Shoji-Ozaki method

について考える.

# Kessler method

$$dX_t = b_\theta(X_t)dt + \sigma_\theta(X_t)dW_t$$

というような自励系の ergodic な確率過程を考える.  
ここで

$$t_j^n = i\Delta_n$$

とにおいて, この幅で離散化することを考える.  
ここで, Ito-Taylor 展開を考え,

$$r_l(\Delta_n, x, \alpha) = \sum_{i=0}^l \frac{\Delta_n^i}{i!} L_\alpha^i f(x)$$

という第  $l$  項まで展開したものを考える.

# Kessler method

このとき,  $n\Delta_n^p \rightarrow 0$  であるとする.  $k_0 = [p/2]$  と定めると次のようにして, 尤度を定めることができる.

$$l_{p,n}(\alpha) = \sum_{i=1}^n \frac{(X_{t_i^n} - r_{k_0}(\Delta_n, X_{t_{i-1}^n}, \alpha))^2}{\Delta_n \sigma_{i-1}^2(\theta)} \left\{ 1 + \sum_{j=1}^{k_0} \Delta_n^j d_j(X_{t_{i-1}^n}, \alpha) \right\} \\ + \sum_{i=1}^n \left\{ \log \sigma_{i-1}^2(\theta) + \sum_{j=1}^{k_0} \Delta_n^j e_j(X_{t_{i-1}^n}, \alpha) \right\}$$

ただし,  $d_j, e_j$  は特別な関数の Taylor 展開をしたときの係数である.



# Simulated likelihood method

$p_\theta(\Delta, y|x)$  を求めることを考える.  $\delta \ll \Delta$  とする. このとき,

$$p_\theta(\Delta, y|x) = \int p_\theta(\delta, y|z)p_\theta(\Delta - \delta, z|x)dz = E_z[p_\theta(\delta, y|z)|\Delta - \delta]$$

であることがわかる. ここで, 右の期待値を Monte Carlo 法によって求めると,  $p_\theta(\Delta - \delta, z|x)$  は正規分布であるので,

$$\hat{p}_\theta^{(N,M)}(\Delta, X_{t+\Delta}|x) = \frac{1}{M} \sum_{i=1}^M \phi_\theta(\delta, X_{t+\Delta}|z_i)$$

として, 確率密度関数を求めることができる.

# Hermite polynomials expansion of the likelihood

$$H_j(z) = e^{\frac{z^2}{2}} \frac{d^j}{dz^j} e^{-\frac{z^2}{2}}$$

という修正 Hermite 多項式を考える.

$$F(\gamma) = \int_0^\gamma \frac{du}{\sigma_\theta(u)}$$

という Lamperti 変換を加えることによって, まず

$$dY_t = \mu_Y(Y_t, \theta)dt + dW_t$$

という風に変換する. その次に,

$$Z = \Delta^{-1/2}(Y - y_0)$$

という変換を施す.

# Hermite polynomials expansion of the likelihood

$$p_Z(\Delta, z|y_0, \theta) = \Delta^{1/2} p_Y(\Delta, \Delta^{1/2} z + y_0|y_0, \theta)$$

という確率密度関数を求めることを考える. ここで,  $H_j(z)/\sqrt{j!}$  は  $L^2$  空間の直交基底であることを使うと,  $p_Z$  を分解することができる. そして, その展開を途中で打ち切ることによって, 尤度の近似を行う.